

Modélisation de la Dépendance par Copules

Application à la Gestion des Risques Multi-Actifs
et aux Produits Dérivés Multi-Sous-Jacents

Article de recherche appliquée

Samy El Mouttalibi

Université Paris Dauphine – PSL | CY Tech

Résumé

Dans un environnement de marché marqué par la guerre en Iran, une stagflation rampante en zone euro et une volatilité multi-actifs sans précédent depuis 2008, la modélisation de la dépendance entre actifs n'a jamais été aussi critique. Cet article présente un cadre mathématique rigoureux pour l'utilisation des copules en gestion des risques multi-actifs et en pricing de produits dérivés multi-sous-jacents. Nous développons le théorème de Sklar avec preuve, les familles de copules (elliptiques, archimédiennes, vine) avec leurs propriétés de dépendance en queue, et leurs applications concrètes au pricing de basket options, worst-of/best-of et correlation swaps. Des simulations Monte Carlo originales montrent que le choix de la copule impacte les prix de $\pm 10\%$ et les mesures de risque (VaR 99%) jusqu'à $+23\%$ par rapport au modèle gaussien standard. Nous montrons pourquoi la copule gaussienne, standard de l'industrie pré-2008, sous-estime systématiquement le risque extrême, et pourquoi les copules de queue (t-Student, Clayton, Gumbel, vine) constituent une réponse méthodologique mieux adaptée au contexte de crise de 2026. Cet article s'appuie sur et étend en contexte financier une approche initialement développée pour la tarification de contrats d'assurance multi-garanties via les copules.

Table des matières

1	Introduction : la dépendance au cœur des marchés actuels	4
2	Limites des approches classiques de la dépendance	4
2.1	La corrélation linéaire de Pearson : un outil insuffisant	4
2.2	La crise de la corrélation gaussienne : leçons de 2008 et 2026	5
2.3	Mesures de dépendance robustes	5
3	Fondements mathématiques des copules	6
3.1	Fonctions de répartition et structure de dépendance	6
3.2	Transformation de probabilité intégrale (PIT)	6
3.3	Définition formelle d’une copule	6
3.4	Le théorème de Sklar	7
3.5	Bornes de Fréchet–Hoeffding	8
3.6	Coefficients de dépendance en queue	8
3.7	Méthode IFM (Inference Functions for Margins)	9
4	Familles de copules et leurs propriétés	9
4.1	Copules elliptiques	10
4.1.1	Copule gaussienne	11
4.1.2	Copule t-Student	11
4.2	Copules archimédiennes	11
4.2.1	Copule de Clayton, dépendance en queue inférieure	12
4.2.2	Copule de Gumbel, dépendance en queue supérieure	12
4.2.3	Copule de Frank, dépendance symétrique	12
4.3	Copules de vine : modélisation flexible en haute dimension	13
4.3.1	Construction théorique des arbres vine	13
4.3.2	CDFs conditionnelles : la clé de l’estimation	14
4.3.3	Estimation séquentielle et sélection	14
4.3.4	Validation par transformation de Rosenblatt	14
5	Application au pricing de produits dérivés multi-sous-jacents	15
5.1	Basket options : le problème de la distribution du panier	15
5.1.1	Architecture de pricing par simulation copulaire	15
5.2	Worst-of et best-of options	16
5.2.1	Worst-of call	16
5.2.2	Best-of call	17
5.2.3	Bornes analytiques sur les prix et lien avec Fréchet	17
5.3	Greeks en régime copulaire	18
5.4	Spread options et correlation swaps	18
5.4.1	Spread options	18
5.4.2	Correlation swaps	18
6	Application à la gestion des risques multi-actifs	19

6.1	VaR et Expected Shortfall sous dépendance copulaire	19
6.1.1	Non-sous-additivité de la VaR et contre-exemple copulaire	19
6.1.2	Sous-additivité de l'ES et lien avec la copule	20
6.2	Changements de régime et matrices de dépendance	21
6.3	Stress testing conditionnel par copule	21
6.4	Détection de changements de régime	22
7	Points méthodologiques et bonnes pratiques	22
7.1	Calibration et sélection de la copule	22
7.2	Gestion des variables mixtes : PIT randomisée	22
7.3	Limites et garde-fous	23
8	Discussion et conclusion	23
8.1	Bilan des apports	23
8.2	Limites identifiées	23
8.3	Perspectives de recherche	24

1 Introduction : la dépendance au cœur des marchés actuels

Le contexte financier d’avril 2020 constitue un environnement d’étude particulièrement révélateur pour la modélisation de la dépendance. La guerre en Iran a provoqué le choc d’offre pétrolier le plus sévère de l’histoire, une réduction de plus de 10 millions de barils par jour — entraînant une contagion simultanée sur l’ensemble des classes d’actifs : actions, taux, devises, matières premières. Dans ce régime de crise, les corrélations entre actifs normalement décorrélés ont convergé vers 1, illustrant précisément le phénomène que la théorie des copules cherche à capturer : la *dépendance extrême en queue de distribution*.

Dans le même temps, les banques centrales naviguent dans une configuration de quasi-stagflation inédite. La BCE maintient ses taux directeurs à 2,00 % (taux de dépôt) dans un contexte d’inflation remontée à 2,6 % et de croissance effondrée à 0,9 % en zone euro. La Fed, divisée comme jamais depuis 1992, maintient sa fourchette à 3,50–3,75 % face à une incertitude géopolitique persistante. Sur les marchés obligataires, les taux longs remontent simultanément dans toutes les zones géographiques — l’OAT 10 ans frôle 3,9 %, son plus haut depuis 2009. L’or a franchi 4 732 \$ l’once, record historique.

C’est précisément dans ces configurations de stress que les modèles basés sur la corrélation linéaire de Pearson révèlent leurs limites structurelles, et que les copules deviennent indispensables. Cet article se propose de développer ce cadre méthodologique avec rigueur, depuis les fondements mathématiques jusqu’aux applications concrètes en trading de dérivés et en gestion des risques. Il s’inspire directement d’un travail conduit en contexte assurantiel pour la tarification de contrats multi-garanties via les copules [11], en transposant la méthodologie vers la finance de marché.

Problématique centrale. Comment modéliser la structure de dépendance entre actifs financiers de façon à capturer fidèlement les co-mouvements extrêmes, calibrer correctement les produits multi-sous-jacents, et évaluer le risque agrégé d’un portefeuille sans sous-estimer les queues de distribution, en particulier dans les régimes de crise observés en 2020 ?

La structure de l’article est la suivante. Après avoir rappelé les limites des approches classiques (Section 2), nous développons les fondements mathématiques des copules avec leurs preuves (Section 3). La Section 4 présente les principales familles paramétriques. Les Sections 5 et 6 détaillent les applications au pricing de dérivés et à la gestion des risques. La Section 7 conclut sur les points méthodologiques.

2 Limites des approches classiques de la dépendance

Avant d’introduire le cadre copulaire, il est essentiel de comprendre les limites des outils traditionnellement utilisés pour mesurer la dépendance entre actifs. La corrélation linéaire de Pearson constitue l’indicateur le plus employé dans les modèles financiers classiques. Elle souffre cependant de plusieurs limitations majeures lorsqu’elle est appliquée à des données de marché.

2.1 La corrélation linéaire de Pearson : un outil insuffisant

Définition 2.1 (Corrélation de Pearson). Le coefficient de corrélation linéaire entre deux actifs X et Y est défini par

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Ce coefficient mesure exclusivement la force d'une relation affine entre deux variables. Dans un cadre financier, son usage comme mesure universelle de dépendance repose sur une hypothèse implicite de normalité conjointe qui est systématiquement violée dans les données de marché.

Quatre limites structurelles rendent la corrélation de Pearson inadaptée à la gestion des risques multi-actifs. Premièrement, l'**insensibilité aux queues de distribution** : une corrélation de 0,3 entre deux actifs peut masquer une probabilité de co-chute extrême très élevée. La corrélation agrège l'information sur l'ensemble de la distribution sans distinguer les zones centrales des extrêmes. Deux portefeuilles peuvent ainsi avoir la même corrélation de Pearson et des comportements radicalement différents lors d'un krach. Deuxièmement, la **non-invariance par transformations monotones** : contrairement au tau de Kendall, ρ change si on applique une transformation monotone (log, racine carrée), rendant les comparaisons entre actifs de nature différente difficiles. Troisièmement, l'**amplification par les valeurs extrêmes** : dans des distributions à queues épaisses, quelques observations extrêmes peuvent artificiellement gonfler la corrélation mesurée, un phénomène bien identifié dans nos données assurantielles sur la garantie *Profits* [11], où la corrélation de Pearson entre montants était de 0,33 alors que les corrélations de Spearman et Kendall étaient quasi nulles, voire négatives. Quatrièmement, l'**instabilité temporelle** : la corrélation entre actifs augmente massivement en période de stress. Entre mars et avril 2026, la corrélation entre le S&P 500 et les Gilts britanniques a changé de signe, illustrant le caractère non-stationnaire de cette mesure.

2.2 La crise de la corrélation gaussienne : leçons de 2008 et 2026

La faillite de Lehman Brothers en 2008 a mis en lumière une défaillance méthodologique fondamentale : les modèles de CDO utilisaient massivement la copule gaussienne pour modéliser la dépendance entre actifs sous-jacents. Cette copule présente une propriété fatale : une dépendance de queue asymptotiquement nulle,

$$\lambda_L = \lambda_U = 0 \quad (\text{copule gaussienne}),$$

quelles que soient les valeurs de la matrice de corrélation. En termes concrets : pour une copule gaussienne, la probabilité de co-chute extrême entre deux actifs tend vers zéro lorsqu'on se concentre sur les queues de distribution, même si la corrélation globale est de 0,9.

En 2026, lors de la phase initiale du conflit iranien, les corrélations réalisées sur 10 jours entre pétrole, taux d'intérêt, actions et devises ont atteint des niveaux comparables à 2008 : la corrélation entre l'or et le S&P 500 est passée de $-0,15$ à $+0,43$, celle entre le Brent et les taux longs de $+0,05$ à $+0,71$. Ces changements de régime sont précisément ce que les copules de queue capturent, et que la copule gaussienne ignore structurellement.

2.3 Mesures de dépendance robustes

Face aux limites de Pearson, deux mesures alternatives permettent de capturer la dépendance monotone de façon invariante par transformations.

Définition 2.2 (Tau de Kendall). Soient (X_1, Y_1) et (X_2, Y_2) deux copies indépendantes de (X, Y) . Le tau de Kendall est :

$$\tau_K(X, Y) = \mathbb{P}[(X_1 - X_2)(Y_1 - Y_2) > 0] - \mathbb{P}[(X_1 - X_2)(Y_1 - Y_2) < 0].$$

Il mesure la probabilité de concordance moins la probabilité de discordance, et vérifie $-1 \leq \tau_K \leq 1$.

Définition 2.3 (Rho de Spearman). Le coefficient de Spearman est la corrélation de Pearson appliquée aux

rangs transformés par les fonctions de répartition :

$$\rho_S(X, Y) = \rho(F_X(X), F_Y(Y)).$$

Ces mesures sont invariantes par transformations monotones et entretiennent une relation directe avec les paramètres des copules, ce qui en fait des outils privilégiés pour la calibration. Pour une copule de Clayton de paramètre $\theta : \tau_K = \theta/(\theta + 2)$. Pour une copule de Gumbel : $\tau_K = 1 - 1/\theta$. Ces relations permettent d'initialiser l'estimation par MLE à partir du τ_K empirique.

3 Fondements mathématiques des copules

3.1 Fonctions de répartition et structure de dépendance

Définition 3.1 (Fonction de répartition jointe). Soit $(X_1, \dots, X_d)$ un vecteur aléatoire. Sa fonction de répartition jointe est définie par

$$F(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

Les fonctions de répartition marginales s'obtiennent par :

$$F_i(x_i) = \lim_{x_j \rightarrow +\infty, j \neq i} F(x_1, \dots, x_d).$$

Connaître uniquement les F_i ne suffit pas à déterminer F : l'information concernant la dépendance entre les variables est perdue. C'est précisément ce à quoi répond l'introduction des copules.

3.2 Transformation de probabilité intégrale (PIT)

Soit X une variable aléatoire réelle de fonction de répartition F_X . Lorsque F_X est continue, la variable transformée $U = F_X(X)$ suit une loi uniforme sur $[0, 1]$. Ce résultat constitue l'outil central permettant de ramener toute variable dans l'espace $[0, 1]$ pour y étudier uniquement la structure de dépendance.

En contexte de portefeuille financier, cette transformation soulève une difficulté lorsque certaines variables présentent une masse de probabilité en un point particulier (spreads de crédit nuls, rendements nuls sur jours fériés). Une telle discontinuité de F_X empêche une application directe de la PIT. La gestion rigoureuse de ces discontinuités, via une PIT randomisée, constitue l'un des défis méthodologiques centraux, identifié également dans notre travail assurantiel pour la garantie *Profits* où plus de 70% des observations étaient nulles [11].

3.3 Définition formelle d'une copule

Définition 3.2 (Copule). Une fonction $C : [0, 1]^d \rightarrow [0, 1]$ est appelée *copule* si elle vérifie :

- (i) C est une fonction de répartition multivariée ;
- (ii) chacune de ses marginales est uniforme sur $[0, 1]$: $C(1, \dots, 1, u_i, 1, \dots, 1) = u_i$ pour tout i .

Propriété 3.1 (Bords nuls). Pour tout $(u, v) \in [0, 1]^2$: $C(u, 0) = 0$ et $C(0, v) = 0$.

Démonstration. Pour tout $u \in [0, 1]$, $C(u, 0) = \mathbb{P}(U \leq u, V \leq 0)$. Comme $V \in [0, 1]$ p.s., $\mathbb{P}(V \leq 0) = 0$, donc $C(u, 0) = 0$. De même, $C(0, v) = \mathbb{P}(U \leq 0, V \leq v) = 0$ car $\mathbb{P}(U \leq 0) = 0$. $\square$

Propriété 3.2 (Marges uniformes). Pour tout $(u, v) \in [0, 1]^2$: $C(u, 1) = u$ et $C(1, v) = v$.

Démonstration. $C(u, 1) = \mathbb{P}(U \leq u, V \leq 1) = \mathbb{P}(U \leq u) = u$ car $V \sim \mathcal{U}[0, 1]$, donc $\mathbb{P}(V \leq 1) = 1$. De même pour $C(1, v) = v$. $\square$

Propriété 3.3 (Condition 2-croissante). Pour tous $0 \leq a_1 \leq a_2 \leq 1$ et $0 \leq b_1 \leq b_2 \leq 1$:

$$C(a_2, b_2) - C(a_1, b_2) - C(a_2, b_1) + C(a_1, b_1) \geq 0.$$

Démonstration. Le membre gauche est égal à $\mathbb{P}(a_1 < U \leq a_2, b_1 < V \leq b_2) \geq 0$ par la formule d'inclusion-exclusion. Cette quantité est la probabilité du rectangle $(a_1, a_2] \times (b_1, b_2]$, qui est bien positive en tant que probabilité. $\square$

3.4 Le théorème de Sklar

Théorème 3.1 (Théorème de Sklar, 1959). Soit F une fonction de répartition multivariée à marges $F_1, \dots, F_d$. Il existe une copule $C : [0, 1]^d \rightarrow [0, 1]$ telle que pour tout $(x_1, \dots, x_d) \in \mathbb{R}^d$:

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d)).$$

Si les marges F_i sont continues, la copule est unique.

Démonstration. Existence. Pour chaque i , posons $U_i = F_i(X_i)$ où $(X_1, \dots, X_d)$ est un vecteur aléatoire de CDF F . Par le théorème de la probabilité intégrale, $U_i \sim \mathcal{U}([0, 1])$ pour tout i (marges continues). On définit

$$C(u_1, \dots, u_d) = \mathbb{P}(U_1 \leq u_1, \dots, U_d \leq u_d), \quad (u_1, \dots, u_d) \in [0, 1]^d.$$

Cette fonction C est une CDF multivariée à marges uniformes, donc une copule. Pour tout $(x_1, \dots, x_d) \in \mathbb{R}^d$, $\{X_i \leq x_i\} \Leftrightarrow \{U_i \leq F_i(x_i)\}$, ce qui donne $F(x_1, \dots, x_d) = \mathbb{P}(U_1 \leq F_1(x_1), \dots, U_d \leq F_d(x_d)) = C(F_1(x_1), \dots, F_d(x_d))$.

Unicité (marges continues). Si C et C' satisfont la relation, alors pour tout $(u_1, \dots, u_d) \in [0, 1]^d$, l'image de $(F_1^{-1}(u_1), \dots, F_d^{-1}(u_d))$ par F est bien définie (les F_i continues couvrent tout $[0, 1]$), donc $C = C'$ sur $[0, 1]^d$. $\square$

Ce théorème justifie la décomposition fondamentale :

$$\underbrace{F(x_1, \dots, x_d)}_{\text{loi jointe}} = C\left(\underbrace{F_1(x_1), \dots, F_d(x_d)}_{\text{lois marginales}}\right).$$

En finance de marché, cette séparation est cruciale : on peut modéliser séparément le smile de volatilité de chaque actif (via sa loi marginale) et la co-dépendance entre actifs (via la copule), sans qu'une spécification influence l'autre.

La figure 1 illustre cette décomposition sur un exemple avec des marginales hétérogènes (normale et log-normale).




FIG. 1 : Décomposition de Sklar : la PIT projette chaque variable dans l'espace uniforme $[0, 1]^2$ (panneau central), séparant les effets marginaux (panneau droit) de la structure de dépendance. La flèche verte indique la transformation PIT ($U_i = F_i(X_i)$); la flèche rouge le sens inverse du théorème de Sklar.

3.5 Bornes de Fréchet–Hoeffding

Proposition 3.1 (Bornes de Fréchet–Hoeffding). *Pour tout $\mathbf{u} \in [0, 1]^d$, toute copule C vérifie :*

$$W(\mathbf{u}) \leq C(\mathbf{u}) \leq M(\mathbf{u}),$$

où $M(\mathbf{u}) = \min(u_1, \dots, u_d)$ (comonotonie parfaite) et $W(\mathbf{u}) = \max(1 - d + \sum_i u_i, 0)$.

Démonstration. Borne supérieure. Pour chaque i , $\{U_1 \leq u_1, \dots, U_d \leq u_d\} \subset \{U_i \leq u_i\}$, donc $C(\mathbf{u}) \leq u_i$. En prenant le minimum sur i : $C(\mathbf{u}) \leq M(\mathbf{u})$.

Borne inférieure. Par l'inégalité de Boole, $\mathbb{P}(A^c) \leq \sum_i \mathbb{P}(U_i > u_i) = \sum_i (1 - u_i)$, donc $C(\mathbf{u}) = \mathbb{P}(A) \geq 1 - d + \sum_i u_i$. Comme $C \geq 0$, on conclut $C(\mathbf{u}) \geq W(\mathbf{u})$. $\square$

Ces bornes décrivent respectivement la comonotonie parfaite (tous les actifs évoluent dans le même sens, cas extrême de contagion) et la contre-monotonie extrême (actifs parfaitement anti-corrélés en rang, possible uniquement en dimension 2). La copule d'indépendance $\Pi(\mathbf{u}) = u_1 \cdots u_d$ est au centre de cet intervalle.

3.6 Coefficients de dépendance en queue

Définition 3.3 (Coefficients de dépendance en queue). Les coefficients de dépendance en queue inférieure et supérieure sont :

$$\lambda_L = \lim_{u \rightarrow 0^+} \mathbb{P}(Y \leq F_Y^{-1}(u) \mid X \leq F_X^{-1}(u)), \quad (1)$$

$$\lambda_U = \lim_{u \rightarrow 1^-} \mathbb{P}(Y > F_Y^{-1}(u) \mid X > F_X^{-1}(u)). \quad (2)$$

Proposition 3.2. *Pour une copule C bivariée :*

$$\lambda_L = \lim_{u \rightarrow 0^+} \frac{C(u, u)}{u}, \quad \lambda_U = \lim_{u \rightarrow 1^-} \frac{1 + C(u, u) - 2u}{1 - u}.$$

Démonstration. Queue inférieure. Par définition de la probabilité conditionnelle :

$$\mathbb{P}(U \leq u \mid V \leq u) = \frac{\mathbb{P}(U \leq u, V \leq u)}{\mathbb{P}(V \leq u)} = \frac{C(u, u)}{u}.$$

Queue supérieure. $\mathbb{P}(U > u, V > u) = 1 - 2u + C(u, u)$ (complémentaire et inclusion-exclusion), donc $\mathbb{P}(U > u \mid V > u) = (1 - 2u + C(u, u))/(1 - u)$. $\square$

En termes financiers, $\lambda_U > 0$ signifie que si un actif connaît un rendement extrêmement élevé (supérieur à son quantile u), la probabilité que l'autre actif connaisse également un rendement extrême reste non nulle même asymptotiquement. C'est la formalisation mathématique de la *contagion financière* en période de crise.

3.7 Méthode IFM (Inference Functions for Margins)

En pratique, les fonctions de répartition marginales ne sont pas connues et doivent être estimées. La méthode IFM procède en deux étapes.

Étape 1, Estimation des marginales. Pour chaque actif j , on estime $\hat{F}_j$ par MLE sur les données individuelles $\{x_{ij}\}_{i=1}^n$. Pour une observation x_i , la pseudo-observation est $\hat{u}_{ij} = \hat{F}_j(x_{ij})$.

Étape 2, Estimation de la copule. On maximise la log-vraisemblance copulaire sur les pseudo-observations :

$$\hat{\theta}_C = \arg \max_{\theta} \sum_{i=1}^n \log c_{\theta}(\hat{u}_{i1}, \dots, \hat{u}_{id}),$$

où $c_{\theta} = \partial^d C_{\theta} / \partial u_1 \cdots \partial u_d$ est la densité de la copule.

Cette séparation garantit que la spécification des marginales n'interfère pas avec l'estimation de la dépendance, et réciproquement. La sélection du modèle copulaire repose ensuite sur les critères $AIC = -2\ell(\hat{\theta}) + 2k$ et $BIC = -2\ell(\hat{\theta}) + k \log n$.

4 Familles de copules et leurs propriétés

Les copules se déclinent en plusieurs familles, chacune possédant des propriétés structurelles permettant de représenter différentes formes de dépendance. Dans un contexte de finance de marché, il est essentiel de disposer de modèles capables de capturer les co-mouvements extrêmes, car la dépendance entre actifs en situation de stress influence directement le pricing et les mesures de risque.

La figure 2 présente les nuages de points des quatre principales familles à tau de Kendall équivalent ($\tau_K \approx 0,40$).

**Structures de dépendance des principales familles de copules
(tau de Kendall ≈ 0.40 pour chaque copule)**




FIG. 2 : Nuages de points dans l'espace copule $[0, 1]^2$ pour quatre familles à $\tau_K \approx 0.40$. Les points en rouge signalent la concentration dans les queues inférieures (coin bas-gauche) et supérieures (coin haut-droit). La copule gaussienne ne présente aucune concentration en coin : $\lambda_L = \lambda_U = 0$. La t-Student concentre dans les deux coins (dépendance bilatérale). Clayton concentre uniquement en bas-gauche ($\lambda_L > 0, \lambda_U = 0$). Gumbel concentre uniquement en haut-droit ($\lambda_U > 0, \lambda_L = 0$).

4.1 Copules elliptiques

Les copules elliptiques sont issues de la famille des distributions elliptiques. Ces distributions se caractérisent par la représentation stochastique $X = \mu + RAU$, où μ est un vecteur de moyennes, A est une matrice telle que $AA^\top = \Sigma$, U est uniforme sur la sphère unité, et R est une variable positive contrôlant l'épaisseur des queues. La dépendance entre composantes est entièrement gouvernée par Σ , et le théorème de Sklar garantit l'existence d'une copule associée.

4.1.1 Copule gaussienne

La copule gaussienne est obtenue en appliquant le théorème de Sklar à la loi normale multivariée centrée réduite :

$$C_{\Sigma}(\mathbf{u}) = \Phi_{\Sigma}(\Phi^{-1}(u_1), \dots, \Phi^{-1}(u_d)),$$

où Φ est la CDF de la loi normale standard et Φ_{Σ} est la CDF de la normale multivariée de matrice de corrélation Σ .

La copule gaussienne hérite de la structure de corrélation linéaire du modèle normal, mais ne transmet pas la dépendance extrême. La loi normale multivariée impose une asymptotie d'indépendance dans les queues : $\lambda_L = \lambda_U = 0$, quelle que soit la matrice Σ . Ainsi, deux actifs fortement corrélés dans la zone centrale de leur distribution deviennent asymptotiquement indépendants lorsque l'on se concentre sur les événements extrêmes, propriété fondamentalement incompatible avec la réalité des marchés en crise.

C'est la copule du modèle de Black-Scholes multi-actifs et du modèle de Li (2000) pour les CDO [3]. Elle est simple, analytique, facilement calibrable, et sous-estime systématiquement le risque extrême.

4.1.2 Copule t-Student

La copule t-Student est issue de la loi t multivariée à ν degrés de liberté, obtenue dans la représentation elliptique lorsque la variable radiale R suit une loi lourde ($R^2 \sim \chi^2(\nu)/\nu$) :

$$C_{\nu, \Sigma}(\mathbf{u}) = t_{\nu, \Sigma}(t_{\nu}^{-1}(u_1), \dots, t_{\nu}^{-1}(u_d)),$$

où t_{ν} désigne la CDF de la loi t univariée.

Contrairement à la copule gaussienne, la copule t-Student transmet une dépendance de queue *bilatérale* :

$$\lambda_U = \lambda_L = 2 t_{\nu+1} \left(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right) > 0,$$

où ρ est la corrélation linéaire entre composantes. Plus ν est faible, plus la dépendance de queue est forte. Pour $\nu \rightarrow \infty$, on retrouve la copule gaussienne ($\lambda_L = \lambda_U \rightarrow 0$).

En pratique, $\nu \in \{4, 5\}$ capture bien les co-chutes observées lors des crises financières. C'est la copule de choix pour un structureur souhaitant pricer un worst-of ou un basket option en période de forte incertitude, car elle capte la probabilité que *tous* les actifs chutent simultanément.

4.2 Copules archimédiennes

Les copules archimédiennes reposent sur une *fonction génératrice* $\varphi : [0, 1] \rightarrow [0, +\infty]$, strictement décroissante et convexe, $\varphi(1) = 0$, admettant une pseudo-inverse $\varphi^{[-1]}$. En dimension deux :

$$C(u, v) = \varphi^{[-1]}(\varphi(u) + \varphi(v)).$$

L'additivité interne est la clé : toute la structure de dépendance est encodée dans la forme de φ et de son paramètre θ . Ces copules ne requièrent pas de matrice de corrélation et offrent une calibration directe à partir du tau de Kendall.

4.2.1 Copule de Clayton, dépendance en queue inférieure

La génératrice de Clayton est $\varphi(t) = (t^{-\theta} - 1)/\theta$, $\theta > 0$, ce qui donne :

$$C_{\text{Clay}}(u, v) = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}.$$

Cette génératrice amplifie les probabilités proches de zéro, se traduisant par une forte dépendance dans la queue gauche : $\lambda_L = 2^{-1/\theta} > 0$, $\lambda_U = 0$.

La copule de Clayton modélise donc la co-chute des actifs sans capturer les co-hausses extrêmes. En finance, elle est adaptée à la modélisation du risque de crédit (défauts simultanés en bas de cycle) et à la couverture de portefeuilles dont on craint la co-baisse (par exemple, actions et obligations convertibles en période de stress de crédit).

4.2.2 Copule de Gumbel, dépendance en queue supérieure

La génératrice de Gumbel est $\varphi(t) = (-\log t)^\theta$, $\theta \geq 1$, donnant la copule d'extrêmes valeurs :

$$C_{\text{Gumb}}(u, v) = \exp\left\{-\left[(-\log u)^\theta + (-\log v)^\theta\right]^{1/\theta}\right\}.$$

Elle présente $\lambda_U = 2 - 2^{1/\theta} > 0$, $\lambda_L = 0$. C'est une copule d'extrêmes valeurs, stable par maxima : si C est une copule de Gumbel, alors la loi des maxima partiels suit le même type de copule.

La copule de Gumbel est naturelle pour le pricing de best-of options (on parie sur le meilleur performeur, donc sur les co-hausses extrêmes) et pour la modélisation de l'exposition simultanée de plusieurs garanties à un même événement catastrophique, analogie directe avec notre traitement assurantiel où la Gumbel capturerait la co-occurrence des sinistres extrêmes sur les garanties *Building* et *Contents* [11].

4.2.3 Copule de Frank, dépendance symétrique

La génératrice de Frank est $\varphi(t) = -\ln[(e^{-\theta t} - 1)/(e^{-\theta} - 1)]$, $\theta \in \mathbb{R}^*$, donnant :

$$C_{\text{Frank}}(u, v) = -\frac{1}{\theta} \ln\left\{1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1}\right\}.$$

Elle est symétrique avec $\lambda_L = \lambda_U = 0$: adaptée aux situations de dépendance modérée symétrique, comme entre deux actifs liés dans la zone centrale mais indépendants dans les extrêmes.

La figure 3 illustre les coefficients de dépendance en queue en fonction des paramètres pour les principales familles.




FIG. 3 : Gauche : coefficient bilatéral $\lambda_U = \lambda_L$ de la copule t-Student en fonction de ρ pour différents degrés de liberté ν — plus ν est petit, plus la dépendance extrême est forte. $\nu = 20$ approche déjà la copule gaussienne ($\lambda \approx 0$). Droite : asymétrie de la dépendance en queue pour Clayton (λ_L) et Gumbel (λ_U) en fonction du tau de Kendall τ_K — à même τ_K , Clayton et Gumbel ont des comportements en queue radicalement différents.

TAB. 1 : Propriétés des principales familles de copules

Copule	Paramètre	λ_L	λ_U	Usage typique
Gaussienne	Matrice Σ	0	0	Pricing standard, CDO
t-Student	Σ, ν	> 0 (sym.)	> 0 (sym.)	Dérivés en crise
Clayton	$\theta > 0$	$2^{-1/\theta}$	0	Risque crédit
Gumbel	$\theta \geq 1$	0	$2 - 2^{1/\theta}$	Best-of, extrêmes
Frank	$\theta \in \mathbb{R}^*$	0	0	Dépendance modérée

4.3 Copules de vine : modélisation flexible en haute dimension

En dimension $d > 3$, les copules trivariées paramétriques deviennent restrictives car elles imposent une structure de dépendance homogène entre toutes les paires. Les copules de vine (*Regular Vine Copulas*), introduites par Bedford et Cooke (2001) et développées par Aas et al. [7], résolvent ce problème par une décomposition hiérarchique de la densité jointe en copules bivariées conditionnelles.

4.3.1 Construction théorique des arbres vine

Une vine $\mathcal{V}$ sur d variables est une séquence d'arbres $T_1, T_2, \dots, T_{d-1}$ où chaque arbre T_k a pour nœuds les arêtes de T_{k-1} . La densité jointe se décompose comme :

$$f(u_1, \dots, u_d) = \prod_{k=1}^{d-1} \prod_{(i,j) \in E(T_k)} c_{ij|D_{ij}}(F_{i|D_{ij}}(u_i|\mathbf{u}_{D_{ij}}), F_{j|D_{ij}}(u_j|\mathbf{u}_{D_{ij}})),$$

où D_{ij} est l'ensemble de conditionnement de la paire (i, j) .

Deux structures vine sont particulièrement utilisées en pratique.

C-vine (Canonical vine). L'arbre T_1 est une étoile centrée sur une variable pivot u_1 . En dimension 3, centrée sur u_1 :

$$c(u_1, u_2, u_3) = c_{12}(u_1, u_2) \cdot c_{13}(u_1, u_3) \cdot c_{23|1}(F_{2|1}(u_2|u_1), F_{3|1}(u_3|u_1)).$$

La C-vine est adaptée lorsqu'une variable domine la dépendance globale.

D-vine (Drawable vine). L'arbre T_1 est un chemin $u_1 - u_2 - u_3$. En dimension 3 :

$$c(u_1, u_2, u_3) = c_{12}(u_1, u_2) \cdot c_{23}(u_2, u_3) \cdot c_{13|2}(F_{1|2}(u_1|u_2), F_{3|2}(u_3|u_2)).$$

La D-vine est adaptée aux séries temporelles où la dépendance suit un ordre naturel.

4.3.2 CDFs conditionnelles : la clé de l'estimation

L'ingrédient central de la construction vine est le calcul des CDFs conditionnelles $F_{j|D}(u_j|\mathbf{u}_D)$. Pour une copule bivariable C_{ij} , on obtient :

$$F_{j|i}(u_j|u_i) = \frac{\partial C_{ij}(u_i, u_j)}{\partial u_i}.$$

Pour les familles usuelles, cette dérivée partielle est analytique :

- **Gaussienne** (ρ) : $F_{2|1}(u_2|u_1) = \Phi\left(\frac{\Phi^{-1}(u_2) - \rho\Phi^{-1}(u_1)}{\sqrt{1 - \rho^2}}\right)$
- **Clayton** (θ) : $F_{2|1}(u_2|u_1) = u_1^{-\theta-1}(u_1^{-\theta} + u_2^{-\theta} - 1)^{-1-1/\theta}$
- **Gumbel** (θ) : $F_{2|1}(u_2|u_1) = C(u_1, u_2) \cdot \frac{(-\ln u_1)^{\theta-1}}{u_1 [(-\ln u_1)^\theta + (-\ln u_2)^\theta]^{1-1/\theta}}$

4.3.3 Estimation séquentielle et sélection

L'estimation vine procède arbre par arbre, en deux étapes par paire. Pour chaque paire $(i, j|D_{ij})$ dans l'arbre T_k :

1. On calcule les pseudo-observations conditionnelles $\hat{v}_{i|D_{ij}}$ et $\hat{v}_{j|D_{ij}}$ à partir des paires de l'arbre précédent.
2. On estime le paramètre de la copule bivariable par MLE : $\hat{\theta}_{ij|D_{ij}} = \arg \max_{\theta} \sum_l \log c_{\theta}(\hat{v}_{i|D_{ij,l}}, \hat{v}_{j|D_{ij,l}})$.

La sélection de la famille de copule pour chaque paire repose sur le critère AIC. Le choix de la structure vine (C-vine, D-vine, R-vine générale) est optimisé en maximisant la log-vraisemblance sur l'ensemble de la séquence d'arbres.

4.3.4 Validation par transformation de Rosenblatt

Si la vine est correctement spécifiée, les résidus de Rosenblatt

$$Z_1 = U_1, \quad Z_2 = F_{2|1}(U_2|U_1), \quad Z_3 = F_{3|1,2}(U_3|U_1, U_2)$$

doivent suivre une loi $\mathcal{U}([0, 1])^3$ indépendante. En pratique, on applique des tests d'adéquation à l'uniforme (Kolmogorov-Smirnov, Anderson-Darling) et des diagnostics graphiques (histogrammes, QQ-plots). Dans notre application assurantielle [11], la transformation de Rosenblatt a permis d'identifier des copules dont l'AIC était satisfaisant mais dont la structure conditionnelle était mal spécifiée, et d'identifier une indépendance

conditionnelle entre *Profits* et *Building* une fois *Contents* fixé, résultat invisible avec une copule trivariée.

Exemple 4.1 (Vine C-vine sur portefeuille multi-actifs 2026). Pour un portefeuille (CAC 40, Brent, Or, OAT 10Y, EUR/USD), on retient une C-vine centrée sur le Brent (variable la plus connectée à la crise) :

Arbre T_1 : quatre copules bivariées non-conditionnelles. Brent-CAC 40 : Clayton ($\theta = 1,8$, $\tau_K = 0,47$, $\lambda_L = 0,65$) ; Brent-OAT 10Y : t-Student ($\nu = 4$, $\rho = 0,55$, $\lambda_U = \lambda_L = 0,32$) ; Brent-Or : Frank ($\theta = -1,2$, $\tau_K = -0,13$) ; Brent-EUR/USD : Gaussienne ($\rho = 0,18$).

Arbre T_2 : trois copules bivariées conditionnelles sachant le Brent. CAC 40-OAT 10Y|Brent : Gaussienne ($\rho = -0,22$) ; OAT 10Y-Or|Brent : Clayton rotatée ($\theta = 0,5$) ; Or-EUR/USD|Brent : Copule d'indépendance ($\tau_K \approx 0$).

En tout : 7 copules bivariées capturant des structures radicalement différentes, impossible à représenter avec une seule copule trivariée.

5 Application au pricing de produits dérivés multi-sous-jacents

5.1 Basket options : le problème de la distribution du panier

Une basket option est une option dont le payoff dépend de la performance agrégée d'un panier pondéré de n actifs $S_1, \dots, S_n$:

$$\text{Payoff} = \max\left(\sum_{i=1}^n w_i \frac{S_i(T)}{S_i(0)} - K, 0\right).$$

Le pricing analytique est impossible car la distribution de la somme pondérée ne se ferme pas en général. On recourt à la simulation Monte Carlo copulaire.

5.1.1 Architecture de pricing par simulation copulaire

La procédure de pricing procède en quatre étapes.

1. **Calibration des marginales.** Ajuster la dynamique individuelle de chaque actif : volatilité locale, modèle à sauts ou modèle de Heston capturant le smile de volatilité $\sigma_i(K, T)$.
2. **Calibration de la copule.** À partir des prix observés de produits corrélés (quantos, exchange options, spreads de corrélation implicite), estimer les paramètres de la copule par MLE ou méthode des moments.
3. **Simulation.** Simuler N vecteurs uniformes $(U_1, \dots, U_n)$ selon la copule, puis transformer en rendements via les CDFs inverses : $R_i = F_i^{-1}(U_i)$.
4. **Pricing.** Calculer $\hat{V} = e^{-rT} \mathbb{E}[\text{Payoff}]$ par moyenne Monte Carlo.

La sensibilité du prix à la structure de dépendance est majeure. Le tableau 2 illustre l'impact sur un basket call ATM.

TAB. 2 : Impact de la copule sur le prix d'un basket call ($\sigma_1 = \sigma_2 = 25\%$, $T = 1$ an, $K = 100$, $\rho_{\text{Pearson}} = 0,50$)

Copule	τ_K	Prix basket	$\partial V / \partial S_1$	$\partial V / \partial \sigma$
Gaussienne	$\approx 0,40$	8,42	0,48	0,33
t-Student ($\nu = 5$)	$\approx 0,40$	8,91	0,49	0,35
Clayton ($\tau = 0,33$)	0,33	7,85	0,46	0,31
Gumbel ($\tau = 0,33$)	0,33	9,18	0,51	0,36

L'écart entre la copule gaussienne et la copule de Gumbel (8,42 vs 9,18, soit +9%) illustre l'importance du choix de la structure de dépendance. En périodes de stress, cet écart s'amplifie car les queues réalisées sont plus épaisses que les paramètres historiques.

5.2 Worst-of et best-of options

5.2.1 Worst-of call

Le payoff d'un worst-of call est :

$$\text{Payoff} = \max\left(\min_{i=1,\dots,n} S_i(T)/S_i(0) - K, 0\right).$$

Ce produit est vendu avec un coupon élevé car l'investisseur prend le risque du pire performeur.

La relation fondamentale entre corrélation et prix :

$$\frac{\partial \text{Prix}_{\text{worst-of}}}{\partial \rho} < 0.$$

Plus les actifs sont corrélés, plus le pire performeur tend à rejoindre la moyenne du panier, le worst-of est donc moins risqué pour l'acheteur. En période de forte corrélation (crise 2026), les primes sont comprimées, rendant ces produits moins attractifs pour les émetteurs.

Il est crucial de distinguer l'effet de la corrélation globale de l'effet de la structure de dépendance en queue. La copule de Clayton, avec sa dépendance en queue inférieure $\lambda_L = 2^{-1/\theta}$, produit des prix de worst-of *systématiquement plus élevés* qu'une copule gaussienne à même ρ de Pearson, car elle capture précisément la probabilité que tous les actifs chutent simultanément de façon extrême, ce que la gaussienne ignore.

La figure 4 illustre cette relation et compare les prix obtenus sous différentes copules.




FIG. 4 : Gauche : prix du worst-of call en fonction de ρ pour différentes copules ($\sigma_1 = \sigma_2 = 25\%$, $T = 1$ an, $K = 1$). La pente négative confirme $\partial V / \partial \rho < 0$. La t-Student ($\nu = 4$) produit des prix systématiquement plus élevés que la gaussienne à même ρ , car elle capte la queue inférieure bilatérale. Droite : comparaison à $\rho = 0,5$ pour des copules à $\tau_K \approx 0,40$ — les écarts atteignent $\pm 10\%$, ce qui justifie une calibration soignée en structuration.

5.2.2 Best-of call

Le payoff d'un best-of call est :

$$\text{Payoff} = \max\left(\max_{i=1,\dots,n} S_i(T)/S_i(0) - K, 0\right).$$

La relation est inversée : $\partial V_{\text{best-of}} / \partial \rho < 0$ également, car une corrélation élevée signifie que le meilleur performeur ne surpasse pas autant le panier. La copule de Gumbel, avec sa dépendance en queue supérieure, est ici la plus pertinente.

5.2.3 Bornes analytiques sur les prix et lien avec Fréchet

Les bornes de Fréchet-Hoeffding sur les copules induisent des bornes analytiques sur les prix des produits multi-sous-jacents. En notant $\Pi_i^0 = S_i(T)/S_i(0)$ le rendement brut de l'actif i , sous mesure risque-neutre $\mathbb{Q}$:

Proposition 5.1 (Bornes de prix par comonotonie). *Pour un worst-of call et un best-of call ATM ($K = 1$) :*

$$V_{\text{worst-of}} \leq e^{-rT} \mathbb{E}^{\mathbb{Q}} \left[\max \left(\min_i \Pi_i^0 - 1, 0 \right) \right] \leq e^{-rT} \mathbb{E}^{\mathbb{Q}} [\max(\Pi_1^0 - 1, 0)] = V_{\text{call}_1}, \quad (3)$$

$$V_{\text{worst-of}} \geq e^{-rT} \mathbb{E}^{\mathbb{Q}} \left[\max \left(\sum_i w_i \Pi_i^0 - 1, 0 \right) \right] = V_{\text{basket}}. \quad (4)$$

La borne inférieure correspond à la copule comonotone ($C = M$) : si tous les actifs sont parfaitement corrélés en rang, le worst-of devient le basket et sa valeur est minimale. La borne supérieure correspond à la copule contre-monotone ($C = W$, possible en $d = 2$) : les actifs évoluent en sens opposé, le pire performeur est très bas, le prix est maximal.

Formule de Margrabe pour les exchange options. Dans le cas particulier $n = 2$ et $K = 0$, le best-of call est lié à l'option d'échange d'un actif contre un autre, dont le prix est donné par la formule de Margrabe (1978) :

$$V_{\text{exchange}} = S_1(0) \Phi(d_1) - S_2(0) \Phi(d_2),$$

avec $\sigma^2 = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$, $d_{1,2} = [\ln(S_1(0)/S_2(0)) \pm \frac{1}{2}\sigma^2 T]/(\sigma\sqrt{T})$. Ce prix décroît avec ρ (pour σ_1, σ_2 fixés) car une corrélation élevée réduit la volatilité relative σ . La formule de Margrabe suppose des marginales log-normales et une copule gaussienne. Pour tenir compte de la dépendance en queue, on la remplace par une simulation Monte Carlo avec copule t-Student ou vine.

5.3 Greeks en régime copulaire

Dans un cadre multi-sous-jacents modélisé par copule, les Greeks standards acquièrent une dimension supplémentaire liée à la structure de dépendance.

- **Delta copulaire** : $\partial V/\partial S_i$ dépend non seulement de la dynamique de S_i mais de la copule jointe. Pour un worst-of, le delta par rapport au pire performeur est amplifié par la dépendance en queue.
- **Vanna croisée** : $\partial^2 V/(\partial S_i \partial \sigma_j)$ mesure comment le delta sur S_i change quand la vol de S_j évolue. Cette quantité est non nulle uniquement en présence de dépendance.
- **Correla-gamma (cross-gamma)** : $\partial^2 V/(\partial S_i \partial S_j)$ mesure directement l'exposition à la co-variation des actifs. En pratique, c'est la sensibilité au τ_K de la copule.
- **Vega de corrélation** : $\partial V/\partial \theta$ — dans un modèle copulaire, cette sensibilité doit être exprimée par rapport au paramètre θ de la copule, pas simplement par rapport à ρ de Pearson. Pour une Gumbel, $\partial V/\partial \theta$ capture la sensibilité à la dépendance en queue supérieure.

Ces Greeks copulaires sont essentiels pour le hedging dynamique d'un book de dérivés multi-sous-jacents. Un desk de trading qui ignore la dépendance en queue sous-estime son correla-gamma et se retrouve non-hedgé lors des événements de stress.

5.4 Spread options et correlation swaps

5.4.1 Spread options

Une spread option parie sur la différence de performance entre deux actifs :

$$\text{Payoff} = \max(S_1(T) - S_2(T) - K, 0).$$

Son prix est maximisé quand $\rho \rightarrow -1$ et tend vers zéro quand $\rho \rightarrow 1$. Dans le contexte 2026, les spreads pétrole/gaz (crack spread) et électricité/gaz (spark spread) ont vu leurs structures de dépendance bouleversées par le conflit iranien, rendant toute calibration sur données pré-crise obsolète. C'est l'argument central pour utiliser des copules calibrées sur la volatilité implicite *forward* plutôt que sur des historiques.

5.4.2 Correlation swaps

Un correlation swap est un produit OTC permettant d'échanger la corrélation réalisée contre une corrélation fixe :

$$\text{Payoff} = N_L \cdot (\rho_{\text{réalisée}} - \rho_{\text{fixe}}), \quad \text{avec} \quad \rho_{\text{réalisée}} = \frac{2}{n(n-1)} \sum_{i < j} \rho_{ij, \text{réalisée}}.$$

Le pricing requiert de modéliser la distribution jointe des corrélations réalisées entre toutes les paires, un problème de dépendance de second ordre. En pratique, les *dispersion trades* (vente de variance indice vs achat de variances individuelles) permettent d'approximer l'exposition à la corrélation implicite. Dans le contexte 2026, la corrélation implicite sur l'EuroStoxx 50 a bondi lors du pic de la crise iranienne, créant des opportunités de dispersion trade pour les desks de volatilité.

6 Application à la gestion des risques multi-actifs

6.1 VaR et Expected Shortfall sous dépendance copulaire

Définition 6.1 (VaR et Expected Shortfall). Pour un portefeuille $P = \sum_i w_i S_i$ et un niveau $\alpha \in (0, 1)$:

$$\text{VaR}_\alpha(P) = -\inf\{x \in \mathbb{R} : \mathbb{P}(P \leq x) \geq \alpha\}, \quad (5)$$

$$\text{ES}_\alpha(P) = \mathbb{E}[-P \mid P \leq -\text{VaR}_\alpha(P)]. \quad (6)$$

L'impact de la copule sur ces mesures est asymétrique : il est maximal sur l'ES (qui capture la totalité de la queue de distribution) et moindre sur la VaR (qui ne regarde qu'un quantile). C'est pourquoi Bâle IV a remplacé la VaR par l'ES comme mesure de risque réglementaire : l'ES est cohérente au sens des mesures de risque cohérentes d'Artzner et al. (1999), et bien plus sensible à la structure de dépendance en queue.

6.1.1 Non-sous-additivité de la VaR et contre-exemple copulaire

La VaR n'est pas sous-additive en général : il existe des portefeuilles pour lesquels $\text{VaR}_\alpha(P_1 + P_2) > \text{VaR}_\alpha(P_1) + \text{VaR}_\alpha(P_2)$, ce qui viole l'axiome de diversification et rend la VaR incohérente comme mesure de risque agrégé.

Exemple 6.1 (Violation de la sous-additivité de la VaR). Soient deux actifs X_1, X_2 avec distributions marginales identiques $\mathbb{P}(X_i = -1) = 0,008$ et $\mathbb{P}(X_i = 0,01) = 0,992$, liés par une copule telle que $\mathbb{P}(X_1 = -1, X_2 = -1) = 0$.

Calculons la VaR à 99 % :

- $\text{VaR}_{99\%}(X_1) = 0,01$ (quantile 1 % de X_1) ;
- $\text{VaR}_{99\%}(X_2) = 0,01$ (idem par symétrie) ;
- $\text{VaR}_{99\%}(X_1 + X_2)$.

Si les pertes extrêmes ne se produisent jamais simultanément ($\mathbb{P}(X_1 = -1, X_2 = -1) = 0$), alors $\mathbb{P}(X_1 + X_2 \leq -0,99) = \mathbb{P}(X_1 = -1) + \mathbb{P}(X_2 = -1) = 0,016 > 0,01$, donc $\text{VaR}_{99\%}(X_1 + X_2) = -0,99$. On obtient ainsi :

$$\text{VaR}_{99\%}(X_1 + X_2) = -0,99 > 0,01 + 0,01 = \text{VaR}_{99\%}(X_1) + \text{VaR}_{99\%}(X_2),$$

violation flagrante de la sous-additivité. Ce paradoxe survient précisément parce que la copule concentre la masse dans les queues marginales indépendamment : la diversification apparente est trompeuse.

6.1.2 Sous-additivité de l'ES et lien avec la copule

L'ES est cohérente car elle est sous-additive. On peut l'écrire comme :

$$ES_\alpha(P) = \frac{1}{1-\alpha} \int_\alpha^1 VaR_u(P) du,$$

ce qui la rend insensible au paradoxe précédent. Sa décomposition par copule est instructive. Pour un portefeuille bivarié $P = w_1X_1 + w_2X_2$:

$$ES_\alpha(P) = w_1 \mathbb{E}[X_1 | P \leq VaR_\alpha(P)] + w_2 \mathbb{E}[X_2 | P \leq VaR_\alpha(P)].$$

Les espérances conditionnelles $\mathbb{E}[X_i | P \leq VaR_\alpha(P)]$, appelées *contributions marginales à l'ES*, dépendent directement de la copule jointe : sous une copule à forte dépendance de queue inférieure (Clayton), les deux actifs chutent ensemble dans les scénarios extrêmes, et les contributions marginales sont toutes deux négatives et élevées en valeur absolue, aggravant l'ES du portefeuille.

La figure 5 présente l'impact de la copule sur la distribution des P&L d'un portefeuille équi pondéré de 3 actifs (actions, pétrole, or) avec volatilités [20 %, 35 %, 15 %] et corrélation de Pearson identique $\rho = 0,30$ entre chaque paire.




FIG. 5 : Gauche : distributions des P&L journaliers sous copules gaussienne, t-Student ($\nu = 5$) et Clayton ($\theta = 1$) à corrélation de Pearson identique. Les queues sont plus épaisses sous la t-Student et Clayton. Les traits verticaux indiquent les VaR 99% respectifs. Droite : comparaison VaR 95%, VaR 99% et ES 99% — la t-Student génère jusqu'à +23 % de risque supplémentaire vs la gaussienne, soit 790 k€ de capital manquant sur un portefeuille de 100 M€. Le ratio ES/VaR mesure la dangerosité de la queue : plus il est élevé, plus les pertes au-delà de la VaR sont sévères.

TAB. 3 : Impact de la copule sur les mesures de risque du portefeuille (3 actifs équipondérés, $\rho_{\text{Pearson}} = 0,30$, valeurs indicatives)

Copule	VaR 95 %	VaR 99 %	ES 99 %	ES/VaR
Gaussienne	-2,41 %	-3,42 %	-3,89 %	1,14
t-Student ($\nu = 5$)	-2,63 %	-4,21 %	-5,47 %	1,30
Clayton ($\theta = 1$)	-2,38 %	-3,78 %	-5,12 %	1,35
Gumbel ($\theta = 1,5$)	-2,45 %	-3,55 %	-4,18 %	1,18
Vine C-vine	-2,58 %	-4,05 %	-5,31 %	1,31

Ce tableau met en évidence un résultat important : deux copules peuvent avoir des VaR proches mais des ES très différentes. Clayton et t-Student ont des VaR 99% similaires (-3,78 % et -4,21 %), mais des ES radicalement différentes (-5,12 % et -5,47 %). Cela illustre que la VaR seule est une mesure insuffisante pour distinguer les structures de dépendance.

6.2 Changements de régime et matrices de dépendance

La figure 6 compare les matrices de corrélation de Pearson sur un portefeuille de 5 actifs en régime normal (2025) et en régime de stress (crise iranienne, mars 2026).




FIG. 6 : Matrices de corrélation de Pearson en régime normal (gauche), régime de stress (centre) et variation (droite). En crise, la corrélation Brent/CAC 40 explose de +0,37 et la corrélation Brent/OAT 10Y de +0,45, illustrant le changement de régime. Ces variations correspondent à un passage vers une copule à forte dépendance de queue : les modèles calibrés sur période calme (copule gaussienne ou paramètres pré-crise) sous-estiment massivement le risque réel.

6.3 Stress testing conditionnel par copule

Dans un cadre copulaire, on peut construire des scénarios conditionnels précis. La densité conditionnelle de X_2 sachant $X_1 = x_1$ est :

$$f_{X_2|X_1=x_1}(x_2) = \frac{c(F_1(x_1), F_2(x_2)) \cdot f_2(x_2)}{c_1(F_1(x_1))},$$

où $c_1(u_1) = \int_0^1 c(u_1, u_2) du_2$ est la densité marginale de la copule évaluée en $u_1 = F_1(x_1)$.

Dans le contexte iranien de 2026, un desk de gestion des risques peut calculer : étant donné un choc de -40% sur le Brent (quantile 1% de la marginale), quelle est la distribution attendue des pertes sur le portefeuille actions ? La copule t-Student avec $\nu = 5$ produit une distribution conditionnelle significativement plus chargée en queue qu'une gaussienne à même corrélation, justifiant des provisions de capital plus élevées.

6.4 Détection de changements de régime

Un apport majeur des copules est la possibilité de détecter des changements de structure de dépendance sans modifier les distributions marginales. Sur fenêtre roulante de 60 jours, si le paramètre θ estimé de la copule (ou le τ_K associé) change brutalement, cela signale un changement de régime, indépendamment de l'évolution des volatilités individuelles.

En 2026, cette approche aurait détecté le changement de régime dès les premiers jours du conflit iranien, avant même la remontée significative des volatilités individuelles. C'est l'avantage opérationnel concret de la modélisation copulaire : une *veille de dépendance* en temps réel, indépendante des métriques idiosyncratiques.

7 Points méthodologiques et bonnes pratiques

7.1 Calibration et sélection de la copule

L'estimateur IFM est le standard opérationnel : calibration des marginales par MLE en première étape, puis calibration de la copule sur les pseudo-observations. La log-vraisemblance à maximiser est :

$$\hat{\theta}_C = \arg \max_{\theta} \sum_{i=1}^n \log c_{\theta}(\hat{u}_{i1}, \dots, \hat{u}_{id}).$$

La sélection du modèle repose sur $AIC = -2\ell(\hat{\theta}) + 2k$ et $BIC = -2\ell(\hat{\theta}) + k \log n$. La copule gaussienne avec sa matrice de corrélation pleine a $k = d(d-1)/2$ paramètres ; les copules archimédiennes n'ont qu'un seul paramètre.

Validation par transformation de Rosenblatt. Si la copule est bien spécifiée, les résidus transformés

$$Z_1 = U_1, \quad Z_2 = F_{2|1}(U_2|U_1), \quad Z_3 = F_{3|1,2}(U_3|U_1, U_2)$$

doivent suivre une distribution $\mathcal{U}([0, 1])^3$ indépendante. Cette validation diagnostique va au-delà des critères d'information en vérifiant la structure conditionnelle de la copule. Dans notre contexte assurantiel, cette transformation a permis d'identifier des inadéquations structurelles non détectées par le seul critère AIC.

7.2 Gestion des variables mixtes : PIT randomisée

En finance, de nombreuses variables présentent des masses de probabilité en points particuliers : rendements nuls sur jours fériés, spreads de crédit nuls pour les émetteurs investment grade, volumes nuls hors heures de trading. La PIT standard produit alors des pseudo-observations regroupées, incompatibles avec l'estimation des copules.

La solution est la PIT randomisée [11] : pour une variable mixte avec $\mathbb{P}(X = x_0) > 0$, la pseudo-observation est générée selon

$$U \sim \mathcal{U}[F_X(x_0^-), F_X(x_0)],$$

assurant l'uniformité sur $[0, 1]$ nécessaire à l'estimation copulaire.

7.3 Limites et garde-fous

Plusieurs limites doivent être soulignées pour un usage opérationnel responsable.

Stationnarité. Les copules statiques supposent une structure de dépendance stable dans le temps. En pratique, utiliser des fenêtres roulantes courtes (60–90 jours) pour capturer les changements de régime, au prix d'une instabilité d'estimation. Les copules dynamiques (*time-varying copulas*) constituent une piste de recherche prometteuse.

Dimensionnalité. En très haute dimension ($d > 20$), les vine copulas deviennent computationnellement lourdes. Les *factor-copulas* (une copule latente commune + copules idiosyncratiques) permettent de réduire la dimension tout en conservant une structure de dépendance flexible.

Overfitting. La validation out-of-sample sur les queues de distribution reste le critère ultime pour un usage en gestion des risques. Un modèle copulaire qui performe bien in-sample mais sous-estime les pertes extrêmes est dangereux.

Données de crise sous-représentées. Les copules calibrées sur données calmes sous-estiment structurellement les queues en crise, comme l'illustre le contexte 2026. D'où l'importance du stress testing par scénarios hypothétiques (*forward-looking*, non basés sur l'historique) en complément des modèles copulaires paramétriques.

8 Discussion et conclusion

8.1 Bilan des apports

La conjonction d'un choc géopolitique majeur (guerre en Iran), d'une inflation persistante, d'une stagflation naissante en zone euro et d'une volatilité multi-actifs record place la modélisation de la dépendance au premier rang des priorités méthodologiques. Le contexte de 2026 a montré que les modèles basés sur la corrélation gaussienne échouent précisément là où on en a le plus besoin : dans les queues de distribution, lors des crises.

Le cadre copulaire apporte une réponse structurée. Premièrement, il permet de séparer l'estimation des distributions marginales de la structure de dépendance, offrant une flexibilité de modélisation impossible avec la corrélation de Pearson seule. Deuxièmement, les familles à dépendance de queue capturent les co-mouvements extrêmes que la copule gaussienne ignore structurellement ($\lambda_L = \lambda_U = 0$). Troisièmement, les vine copulas offrent une architecture modulaire permettant d'adapter la structure de dépendance paire par paire, ce que nos résultats empiriques ont confirmé tant en contexte assurantiel [11] qu'en finance de marché.

Sur le plan quantitatif, les simulations conduites montrent que le choix de la copule impacte les prix des worst-of calls jusqu'à $\pm 10\%$, la VaR 99% d'un portefeuille jusqu'à $+23\%$ et l'ES 99% jusqu'à $+41\%$ par rapport au modèle gaussien standard. Ces chiffres représentent des montants de capital économique significatifs sur des portefeuilles institutionnels.

8.2 Limites identifiées

Plusieurs limites doivent cependant être soulignées.

Stationnarité de la structure de dépendance. Les copules paramétriques supposent une structure C stable dans le temps. Or le contexte de 2026 illustre précisément comment la dépendance peut changer brutalement de régime. Les copules calibrées sur données pré-crise sous-estiment la dépendance réalisée en stress. L’usage de fenêtres roulantes courtes (60–90 jours) permet de suivre cette évolution mais introduit une instabilité d’estimation dans les queues où les données sont rares.

Hypothèse d’indépendance marginale et copule. La méthode IFM suppose que la spécification des marginales est indépendante de la structure de dépendance. Cette séparation est théoriquement justifiée mais peut être mise en défaut lorsque les marginales sont elles-mêmes affectées par la dépendance (effets de contagion, contamination des estimateurs en période de crise). L’analogie financier est la dépendance entre volatilité réalisée et corrélation réalisée — l’effet Epps — qui viole cette hypothèse d’indépendance.

Identificabilité en haute dimension. En dimension élevée ($d > 10$), le nombre de paramètres d’une vine R-vine ($d(d-1)/2$ copules bivariées) devient rapidement très grand. La sélection de la structure optimale est alors NP-difficile et nécessite des heuristiques (algorithme de l’arbre couvrant de poids maximum sur le tau de Kendall). Les copules factor-copula, qui réduisent la dimension via des facteurs latents communs, constituent une alternative complémentaire.

Données de stress sous-représentées. Les queues de distribution sont par nature peu observées. Une copule calibrée sur 5 ans de données calmes peut comporter seulement quelques dizaines d’observations dans le quantile 1 %, insuffisant pour estimer précisément λ_L ou λ_U . Le stress testing par scénarios hypothétiques (chocs géopolitiques, dislocation de marché) est indispensable en complément des modèles paramétriques.

8.3 Perspectives de recherche

Copules dynamiques. Les *time-varying copulas* modélisent l’évolution temporelle du paramètre de dépendance via un processus stochastique. Le modèle GARCH copulaire de Patton (2006) paramétrise θ_t comme une fonction ARMA des résidus passés. Les modèles à changement de régime markovien permettent de passer d’un régime de dépendance faible à un régime de dépendance forte de façon discrète.

Copules neuronales. Les *neural copulas* (Kamthe et al., 2021) apprennent la densité copulaire directement à partir des données via des réseaux de neurones normalisant les flots. Elles n’imposent aucune famille paramétrique et capturent des structures de dépendance arbitrairement complexes, au prix d’une moindre interprétabilité et de besoins en données plus importants.

Copules et apprentissage par renforcement. Une direction émergente consiste à utiliser des modèles copulaires pour générer des scénarios adversariaux dans le cadre de la gestion de portefeuille par apprentissage par renforcement, permettant d’optimiser des stratégies robustes aux régimes de crise.

Remarque 8.1 (Synthèse pour le praticien). Pour un desk de trading ou de structuration, la hiérarchie pratique est la suivante. En l’absence de données suffisantes, partir d’une copule t-Student ($\nu = 5$) qui offre une dépendance de queue bilatérale raisonnable sans surparamétrage. Dès que la dimension le permet et que les données sont suffisantes, passer à une vine C-vine ou D-vine avec sélection AIC par paire. Compléter systématiquement par des stress tests conditionnels (Section 6) et une veille du paramètre θ sur fenêtre roulante pour détecter les changements de régime. Ne jamais s’en remettre exclusivement à une copule gaussienne pour des produits dont le payoff dépend des queues de distribution (worst-of, options barrières).

Références

- [1] A. Sklar, Fonctions de répartition à n dimensions et leurs marges, *Publications de l'Institut de Statistique de l'Université de Paris*, **8**, 229–231, 1959.
- [2] R. B. Nelsen, *An Introduction to Copulas*, 2^e éd., Springer, 2006.
- [3] D. X. Li, On default correlation : a copula function approach, *Journal of Fixed Income*, **9**(4), 43–54, 2000.
- [4] P. Embrechts, A. McNeil et D. Straumann, Correlation and dependence in risk management : properties and pitfalls, *RiskLab, ETH Zurich*, 2002.
- [5] H. Joe, *Dependence Modeling with Copulas*, CRC Press, 2015.
- [6] F. Durante et C. Sempi, *Principles of Copula Theory*, CRC Press, 2015.
- [7] K. Aas, C. Czado, A. Frigessi et H. Bakken, Pair-copula constructions of multiple dependence, *Insurance : Mathematics and Economics*, **44**(2), 182–198, 2009.
- [8] U. Cherubini, E. Luciano et W. Vecchiato, *Copula Methods in Finance*, Wiley Finance, 2004.
- [9] E. Marceau, *Modélisation et évaluation des risques en actuariat*, Springer, 2012.
- [10] A. Charpentier et M. Denuit, *Mathématiques de l'assurance non vie*, Tomes 1 & 2, Economica, 2004.
- [11] S. El Mouttalibi, Tarification des contrats multi-garanties via les copules, *Mémoire, Université Paris Dauphine – PSL*, 2026.
- [12] Banque Mondiale, *Rapport sur les marchés mondiaux des matières premières — Impact de la guerre en Iran*, Avril 2026.
- [13] Banque centrale européenne, *Bulletin économique n° 2/2026*, Banque de France / BCE, 2026.
- [14] Euronews, La Fed maintient ses taux, Jérôme Powell annonce qu'il restera au conseil, <https://fr.euronews.com/business/2026/04/29/la-fed-maintient-ses-taux>, 29 avril 2026.
- [15] Anonyme, Copulas and dependence modelling, arXiv :2210.03163, 2022.